

SQL project

Non conoscendo il dataset per prima cosa ho aperto ogni tabella per controllare se notavo subito qualcosa di strano ed effettivamente è stato così. Nella tabella customer abbiamo due duplicati Atlantic Furniture Co. e Pinnacle Electronics che sono presenti due volte e differiscono rispettivamente per '.' e per uno spazio di troppo. Allo stesso modo anche nella tabella carriers troviamo un duplicato: Maersk compare due volte con due nomi differenti. Tutte situazioni che andranno gestite in fase di data cleaning.

Analisi

1.

Nonostante le osservazioni ho deciso di controllare quali fossero i clienti e i carriers più rilevanti per spedizioni e costo pure prima di unire i duplicati in modo da poter effettuare un confronto. Come già preannunciato controllando i dati anagrafici si nota subito degli errori di duplicazioni. Per correggerli ho deciso di creare delle tabelle di supporto in modo da non dover modificare quelle originali: customers2 e carriers2 nelle quali ho cancellato i duplicati e reindirizzato gli id in shipments verso gli unici rimasti. Alla fine ho controllato nuovamente quali fossero i clienti e i carriers più rilevanti per spedizioni e costo e la situazione è notevolmente cambiata. Atlantic Furniture Co è diventato il cliente più rilevante per distacco e Maersk il secondo carrier più rilevante.

2.

Per rispondere alla domanda sulle distribuzioni di 'mode' e 'status' le ho analizzate prima singolarmente e poi incrociate. Per quanto riguarda 'status' questa è la distribuzione: Delivered 253, Delayed 57, In Transit 57, Cancelled 53.

'mode', invece è presente sia nella tabella shipment che nella tabella carriers e la distribuzione a seconda che usi una o l'altra cambia notevolmente. Fra le due ho deciso di usare 'mode' della tabella 'carriers' perché mi è sembrata più consistente e andando a controllare qualche riga su shipments ho trovato molto spesso, per esempio modalità 'air' collegate a carrier chiaramente di tipo marittimo. Quindi la distribuzione di 'mode' è la seguente: Air 88, Road 95, Sea 237.

Incrociando le distribuzioni e concentrandoci in modo particolare sullo status 'delayed' e 'cancelled', quella che salta fuori è la seguente distribuzione:

Modalità	N. spedizioni	% Cancellate	% Ritardate
Air	88	11.4	9.1
Road	95	18.9	10.5
Sea	237	10.5	16.5

Si possono notare pattern interessanti. In particolar modo la percentuale più grande di spedizioni cancellate appartiene alla mode 'Road' (18.9%) probabilmente dato dal fatto che sono le spedizioni più facilmente riprogrammabili. Per quanto riguarda la percentuale di spedizioni in ritardo (16.5%) appartiene alla mode 'Sea' nonostante una cancellazione più bassa. Questi dati sono probabilmente dovuti al fatto che programmare una spedizione via nave richiede un processo più lungo e soggetto a vincoli e che quindi una volta programmata difficilmente viene cancellata ma è la più soggetta a ritardi perché è la più soggetta a imprevisti meteo, con i vari porti o più semplicemente perché è la più lenta nonostante copra distanze paragonabili a quelle aeree.

3.

L'anomalia più grande, individuata prima è sicuramente l'incosistenza tra 'mode' di 'carriers' e 'mode' di 'shipments' sulla quale ho effettuato un confronto ed è risultato che 297 spedizioni su 420 abbiano delle modalità che non coincidono tra cui per esempio modalità 'Road' assegnata a 'Lufthansa Cargo'. Per


correggerli ho deciso di usare la 'mode' di 'carriers' perché con una veloce verifica, data dal fatto che sono relativamente pochi, ho potuto verificare che tipologia di spedizioni effettuassero le suddette compagnie.

Un'altra anomalia interessante è la presenza di 4 spedizioni con un peso inferiore a 0 che è ovviamente impossibile. Potrebbe essere anche solo un semplice errore di inserimento nel quale è stato aggiunto un '-' davanti per sbaglio.

Un'ultima possibile anomalia che ho individuato riguarda il costo per kg, in particolare salta all'occhio una spedizione su strada che ha un costo estremo di circa 36 euro per kg di merce. Non è sicuro che sia un errore ma il dubbio c'è e l'unico modo per accertarsi in questo caso è controllare specificatamente di che merce si tratta.

4.

Se dovessi scegliere una singola metrica da monitorare ogni settimana opterei per la percentuale di consegne arrivate puntuali sul totale delle consegne perché credo che per il cliente la puntualità della consegna sia un fattore fondamentale e di conseguenza anche per l'azienda che si occupa della logistica in quanto una consegna puntuale porterà a una fidelizzazione del cliente maggiore. Inoltre un monitoraggio su base settimanale di questa metrica permette di intervenire in tempi relativamente veloci sulla possibile causa del problema e risolverla per evitare costi imprevisti o per evitare che si ripetano gli stessi inconvenienti.



Codice SQL

```
-- controllo tutte le tabelle
SELECT*
FROM shipments;

SELECT*
FROM carriers;

SELECT*
FROM customers;

-- 1
-- calcolo il numero delle spedizioni e il loro costo rispettivamente
-- per i clienti che per i corrieri e li ordino in ordine decrescente
SELECT customer_name,
COUNT(shipment_id) n,
ROUND(SUM(freight_cost_eur)) somma_costo
FROM shipments ship
JOIN customers cus
ON ship.customer_id=cus.customer_id
```

```

GROUP BY cus.customer_id
ORDER BY somma_costo DESC;

SELECT carrier_name,
COUNT(shipment_id) n,
ROUND(SUM(freight_cost_eur)) somma_costo
FROM carriers car
JOIN shipments ship
ON car.carrier_id=ship.carrier_id
GROUP BY car.carrier_id
ORDER BY somma_costo DESC;

-- data cleaning
-- creo una tabella di supporto per customer in modo da non intaccare quella originale
-- e identifico e elimino i nomi duplicati
DROP TABLE IF EXISTS customers2;
CREATE TABLE customers2 AS SELECT * FROM customers;
SELECT *
FROM (
SELECT
TRIM(customer_name),
ROW_NUMBER() OVER (
PARTITION BY TRIM(customer_name, '.')
) AS row_num
FROM
customers2
) duplicates
WHERE
row_num > 1;

WITH duplicati AS (
SELECT
rowid,
ROW_NUMBER() OVER (
PARTITION BY TRIM(customer_name, '.')
ORDER BY customer_name ASC
) AS row_num
FROM
customers2
)
DELETE FROM customers2
WHERE rowid IN (
SELECT rowid
FROM duplicati
WHERE row_num > 1
);
SELECT *
FROM carriers;
--creo una tabella di supporto per carrier in modo da non intaccare quella originale
-- e identifico e elimino i nomi duplicati
DROP TABLE IF EXISTS carriers2;
CREATE TABLE carriers2 AS SELECT * FROM carriers;

WITH duplicati AS (
SELECT rowid,
ROW_NUMBER() OVER (

```

```

PARTITION BY SUBSTR(carrier_name || ' ', 1, INSTR(carrier_name || ' ' - 1)
ORDER BY LENGTH(carrier_name) ASC
) AS row_num
FROM carriers2
)
DELETE FROM carriers2 WHERE rowid IN (SELECT rowid FROM duplicati WHERE row_num > 1);
-- ricongiungo gli id che si riferiscono ai customers cancellati a quelli rimasti che hanno lo stesso nome
WITH mappatura AS (
SELECT
c_originale.customer_id AS id_vecchio, -- L'ID della tabella originale 'customers'
c_pulita.customer_id AS id_nuovo -- L'ID della tabella pulita 'customers2'
FROM
customers c_originale
JOIN
customers2 c_pulita
ON RTRIM(c_originale.customer_name, '.') = RTRIM(c_pulita.customer_name, '.')
)
UPDATE shipments
SET customer_id = (
SELECT id_nuovo
FROM mappatura
WHERE id_vecchio = shipments.customer_id
)
WHERE customer_id IN (
SELECT id_vecchio
FROM mappatura
WHERE id_vecchio != id_nuovo
);
-- ricongiungo gli id che si riferiscono ai carriers cancellati a quelli rimasti che hanno lo stesso nome
WITH mappatura2 AS (
SELECT
c_originale.carrier_id AS id_vecchio,
c_pulito.carrier_id AS id_nuovo
FROM carriers c_originale
JOIN carriers2 c_pulito
ON SUBSTR(c_originale.carrier_name || ' ', 1, INSTR(c_originale.carrier_name || ' ' - 1)
IS SUBSTR(c_pulito.carrier_name || ' ', 1, INSTR(c_pulito.carrier_name || ' ' - 1)
)
UPDATE shipments
SET carrier_id = (SELECT id_nuovo FROM mappatura2 WHERE id_vecchio = shipments.carrier_id)
WHERE carrier_id IN (SELECT id_vecchio FROM mappatura2 WHERE id_vecchio != id_nuovo);
-- ricontrollo le classifiche di costi e numero di spedizioni dopo aver aggiornato le tabelle
SELECT customer_name,
COUNT(shipment_id) n,
ROUND(SUM(freight_cost_eur)) somma_costo
FROM shipments ship
JOIN customers2 cus
ON ship.customer_id=cus.customer_id
GROUP BY cus.customer_id
ORDER BY somma_costo DESC;

SELECT carrier_name,
COUNT(shipment_id) n,
ROUND(SUM(freight_cost_eur)) somma_costo

```

```

FROM carriers2 car
JOIN shipments ship
ON car.carrier_id=ship.carrier_id
GROUP BY car.carrier_id
ORDER BY somma_costo DESC;
-- 2
--distribuzione mode di shipments
SELECT ship.mode, COUNT(*) AS n
FROM shipments ship
GROUP BY mode;
-- distribuzione status di shipments
SELECT status, COUNT(*) AS n
FROM shipments
GROUP BY status;
--distribuzione mode di carriers
SELECT car.mode, COUNT(*) AS n
FROM shipments ship
JOIN carriers2 car
ON ship.carrier_id = car.carrier_id
GROUP BY car.mode
ORDER BY n DESC;
--distribuzione incrocista di status e mode
SELECT
car.mode,
COUNT(*) AS n,
ROUND(100.0 * SUM(CASE WHEN ship.status='Cancelled' THEN 1 ELSE 0 END) / COUNT(*), 1) AS
pct_cancellate,
ROUND(100.0 * SUM(CASE WHEN ship.status='Delayed' THEN 1 ELSE 0 END) / COUNT(*), 1) AS
pct_ritardate
FROM shipments ship
JOIN carriers car ON ship.carrier_id = car.carrier_id
GROUP BY car.mode;
-- 3
-- confronto mode di carriers con mode di shipment per vedere in quanti e quali casi non corrispondono
SELECT
ship.mode AS mode_dichiarato,
car.mode AS mode_reale_carrier,
car.carrier_name,
COUNT(*) AS n_spedizioni
FROM shipments ship
JOIN carriers2 car ON ship.carrier_id = car.carrier_id
WHERE ship.mode <> car.mode
GROUP BY 1, 2, 3
ORDER BY n_spedizioni DESC;

SELECT
SUM(CASE WHEN ship.mode = car.mode THEN 1 ELSE 0 END) AS coerenti,
SUM(CASE WHEN ship.mode <> car.mode THEN 1 ELSE 0 END) AS incoerenti
FROM shipments ship
JOIN carriers2 car ON ship.carrier_id = car.carrier_id;
-- controllo anomalie su peso, volume e costo, in particolare se ci sono valori negativi
SELECT *
FROM shipments
WHERE weight_kg <= 0 OR volume_cbm<=0 OR freight_cost_eur<=0;

```

```
--controllo anomalia di costo su peso
SELECT shipment_id, customer_id, mode, departure_date, arrival_date, freight_cost_eur, weight_kg,
freight_cost_eur/weight_kg
FROM shipments
ORDER BY freight_cost_eur/weight_kg DESC;
```